O corpus do projeto: parágrafos da Wikipédia sobre a Baixada Santista

Grupo 3Mkt

5 de outubro de 2026

Fatec Baixada Santista – Rubens Lara
Tecnologia em Ciência de Dados | Projeto Integrador III — Motor de Busca | Prof. Dr. João Paulo Ferreira de Mello

João Pedro – RA 0051352511002
Lucas Marques – RA 0051352511024
Timóteo Blank – RA 0051352511014

Repositório: `3mkt-pi3`

1 Introdução

O tema deste motor de busca é a Baixada Santista: seus bairros, praias e municípios, e a história e os problemas que os acompanham. Quem o usaria é alguém de fora ou de dentro da região, como por exemplo um comprador de imóvel, um estudante, uma família em busca de passeio, que tem uma dúvida concreta e quer o trecho de texto que a responde, não uma lista de páginas. Em recuperação de informação, o que se atende é a *necessidade de informação* de alguém, não a consulta literal; por isso as perguntas vêm antes do corpus. O motor deve responder a três delas:

- **q01**: "Quero comprar uma casa e preciso saber se o Gonzaga é um lugar calmo para se viver."
- **q02**: "Vou fazer um trabalho sobre recuperação ambiental e quero entender se Cubatão ainda sofre com poluição industrial ou se o cenário melhorou."
- **q03**: "Quero levar minha família para um passeio cultural e preciso saber quais são os monumentos mais importantes sobre a fundação de São Vicente."

Este texto apresenta a fonte escolhida, descreve como o corpus foi montado e mostra, com evidência, até onde ele tem condição de responder a essas perguntas.

2 A fonte e o documento

O texto vem da Wikipédia (Wikimedia Foundation, 2026) em português, obtido pela API do MediaWiki em texto puro, sob a licença CC BY-SA, com acesso em 11/09/2026. Foram pedidas 16 artigos: oito bairros de Santos (Gonzaga, Boqueirão, Ponta da Praia, José Menino, Aparecida, Macuco, Vila Mathias e Campo Grande), quatro praias (Tombo, Astúrias, Pitangueiras e Gonzaga) e quatro municípios (Guarujá, São Vicente, Cubatão e Praia Grande). Uma delas, Pitangueiras, não foi encontrada (Seção 3), restando 15 artigos. As perguntas saem dos próprios artigos: Gonzaga para a q01, Cubatão para a q02 e São Vicente para a q03; as demais são vizinhas que fazem o motor distinguir lugares que compartilham vocabulário (*praia*, *bairro*, *cidade*).

O documento é o parágrafo, identificado como `pagina-pN` (por exemplo, `cubatao-p3`). Um parágrafo é a menor unidade que responde sozinha a uma pergunta: o `cubatao-p3` diz que Cubatão foi a cidade mais poluída do mundo e depois se recuperou, e isso basta para a q02. Com o artigo inteiro como documento, o motor diria apenas "a resposta está em Cubatão", sem apontar onde.

O corpus foi escolhido por a região ser conhecida pelos autores e porque a Wikipédia tem licença livre, API estável e texto já em prosa.

3 Como o corpus foi obtido

A coleta roda em R e segue seis passos. (1) Para cada título, uma função chama a API da Wikipédia pedindo o texto puro, segue redirecionamentos, identifica o projeto no *user agent*, espera 1,5 s entre requisições e tenta até cinco vezes com espera crescente; ela avisa quando a página não existe, está vazia (menos de 50 caracteres) ou parece desambiguação. (2) Os títulos que falharam são listados e descartados. (3) Os cabeçalhos de seção (`== ... ==`) são removidos. (4) O texto é dividido nas quebras de linha, e cada parágrafo recebe o identificador do artigo mais seu número. (5) Um filtro mantém só parágrafos com pelo menos 40 caracteres e algum caractere alfanumérico; o limiar de 40 foi escolhido para eliminar títulos residuais e rótulos como "Ver também". (6) O resultado original rendeu 224 parágrafos. Entretanto, após a limpeza manual e remoção de duplicatas exatas, tabelas demográficas soltas e dados ruidosos, 30 linhas de dados foram excluídas. O arquivo consolidado (`corpus.csv`) preservou a padronização e qualidade, resultando em exatos 194 parágrafos válidos.

4 Defesa do corpus

As Tabelas 1 e 2 resumem o corpus atualizado após a limpeza dos ruídos e remoção das duplicatas.

Tabela 1 – Diagnóstico do corpus

Verificação	**Resultado**
Tamanho	$N = 194$ documentos de 12 páginas
Tokens por documento	4 a 227 (média 65,7; mediana 55,5)
Vocabulário bruto	4.371 termos distintos em 12.750 tokens
Página que domina	`Praia Grande (São Paulo)`: 51 de 194 (26,3%)
Documentos suspeitos	26 com menos de 20 tokens; nenhum com mais de 300
Sujeira	189 com acento, 193 com pontuação, 135 com dígitos (de 194)

Fonte: Elaborada pelos autores a partir de `corpus.csv`.

Tabela 2 – Documentos por página de origem (tokens: média por documento)

Página	**Docs**	**Tokens**	**Página**	**Docs**	**Tokens**
Praia Grande	51	68,5	Ponta da Praia	6	47,3
Guarujá	41	71,2	Praia das Astúrias	5	33,4
Cubatão	35	73,4	Aparecida (Santos)	4	45,8
São Vicente	27	74,7	Campo Grande (Santos)	4	37,8
Boqueirão (Santos)	8	37,6	José Menino	4	43,8
Gonzaga (Santos)	7	49,9	Praia do Tombo	2	71,5

Fonte: Elaborada pelos autores.

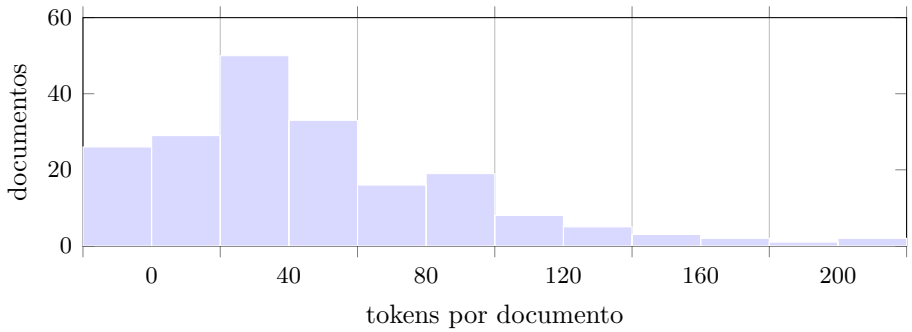
Tamanho. Os 194 documentos bastam para o julgamento da Aula 05. A faixa é folgada, e o risco não é a falta de documentos, mas a qualidade deles, que foi significativamente elevada com o filtro manual. Páginas inteiramente duplicadas (como `Praia do Gonzaga`) e de listas sem prosa contínua foram expurgadas.

Domínio de uma página. Os quatro municípios somam 154 dos 194 documentos (79,4%), e Praia Grande sozinha, 26,3%. Um município tem muito mais a dizer que um bairro, mas desequilibra o corpus: o Gonzaga tem apenas sete documentos próprios contra 51 de Praia Grande. Como as perguntas citam o lugar pelo nome, o desequilíbrio pesa menos, e a correção é acrescentar mais páginas dos bairros (como a orla e o Centro Histórico) no futuro.

Documentos que não são prosa. Os 26 documentos curtos restantes representam sentenças curtas porém informativas (descrições objetivas). Não há documentos longos demais (o maior tem 227 tokens), como mostra a Figura 1.

Sujeira. Quase todos os documentos têm acento (189), pontuação (193) ou dígitos (135). Isso é esperado e preserva a precisão das informações. O `busca_ri.R` normaliza

Figura 1 – Tokens por documento (194 documentos)



Fonte: Elaborada pelos autores.

tudo (minúsculas, sem acentos, só letras e números) e remove as palavras funcionais, o que reduz o vocabulário bruto de 4.371 para cerca de 3.360 termos limpos e representativos.

Os termos mais frequentes no texto bruto são `de`, `a`, `e`, `o`, `do`, `da`, `em`, `que`, `com` e `na`: nenhum diz algo sobre o tema. Depois da limpeza aparecem `sao`, `praia`, `cidade`, `vicente` e `grande`, que descrevem perfeitamente a região.

Veredito. Foram rodadas as três perguntas no `busca_ri.R`, com busca vetorial (TF-IDF e cosseno) e BM25; a Tabela 3 mostra o melhor documento de cada método.

Tabela 3 – Melhor documento de cada pergunta e se ele responde

Perg.	BM25	Vetorial	O corpus responde?
q01	`gonzaga-santos-p3`	`gonzaga-santos-p1`	**Não.** Os documentos do bairro tratam de comércio, shoppings e lazer; os indícios apontam exatamente o contrário de calma.
q02	`cubatao-p3`	`cubatao-p3`	**Em parte.** Traz a poluição dos anos 1980 e a recuperação (título da ONU, 1992), mas falta contexto extenso sobre o cenário atual.
q03	`sao-vicente-sao-paulo-p4`	`sao-vicente-sao-paulo-p4`	**Sim.** Cita a Casa de Taipa, a Igreja Matriz, o Engenho dos Erasmos, a Biquinha de Anchieta, a Ponte Pênsil e a encenação da fundação.

Fonte: Elaborada pelos autores, com `busca_ri.R`.

Os dois métodos concordam no primeiro resultado das três perguntas, o que dá confiança de que o achado vem de fato do corpus, não do método. A q03 é bem atendida; a q02 só responde à parte histórica da recuperação; e a q01 revela uma lacuna: a Wikipédia descreve o Gonzaga estritamente como polo comercial. O descarte das duplicadas funcionou perfeitamente: os textos idênticos que existiam sob "Praia do Gonzaga" foram expurgados, enxugando o espaço de busca sem prejudicar os documentos originais de "Gonzaga (Santos)", que dominaram o ranking. Para a q01, os autores deveriam acrescentar páginas com perfil mais residencial.

Referências

Wikimedia Foundation, 2026